

Tarea 2 Procesamiento de Datos - Análisis de Sentimientos

Irwinng Rodriguez

August 2026

1 Introduction

El análisis de texto constituye una de las principales aplicaciones del Procesamiento, ya que permite transformar información escrita no estructurada en representaciones numéricas que pueden ser analizadas mediante métodos estadísticos.

2 Metodología

Se utilizaron como fuente de información los dos primeros capítulos del libro *Harry Potter y la Piedra Filosofal*. Los documentos fueron almacenados individualmente en archivos de texto plano (`.txt`) y posteriormente procesados utilizando Python.

Los documentos analizados fueron:

- Capítulo 1: *El niño que vivió*.
- Capítulo 2: *El vidrio que se desvaneció*.

Para esta tarea cada capítulo fue tratado como una unidad textual independiente.

2.1 Preprocesamiento del texto

Antes de realizar la vectorización, se implementó un proceso de limpieza y normalización.

El objetivo de este procedimiento fue reducir el ruido y conservar principalmente aquellas palabras con mayor contenido semántico.

2.2 Vectorización TF-IDF

Para transformar el contenido en información numérica se utilizó el método TF-IDF. Este método combina la frecuencia de aparición de un término dentro de un documento con su relevancia en relación con el conjunto total de documentos.

2.3 Análisis de sentimiento

El análisis de sentimiento se realizó mediante un enfoque basado en léxico. Para ello se construyeron dos diccionarios:

- Palabras asociadas con sentimientos positivos.
- Palabras asociadas con sentimientos negativos.

Para cada documento se contabilizó la cantidad de términos positivos y negativos.

3 Resultados

La vectorización produjo una matriz compuesta por dos documentos y 5,505 características.

La matriz obtenida presenta una densidad de 0.50 y una dispersión de 0.50. Este comportamiento se encuentra relacionado con el reducido número de documentos utilizados. Debido a que solamente se analizaron dos capítulos y se estableció un valor de `max_df = 0.95`, los términos presentes simultáneamente en ambos documentos fueron eliminados de esta representación, por lo que las características conservadas tienden a distinguir un capítulo del otro.

En consecuencia, la matriz TF-IDF refleja principalmente vocabulario característico y diferenciador de cada documento.

4 Limitaciones

El análisis presenta algunas limitaciones que deben considerarse al interpretar los resultados.

En primer lugar, solamente se utilizaron dos documentos, por lo que el tamaño del corpus es reducido. Esto influye directamente sobre las propiedades de la representación TF-IDF.

En segundo lugar, el análisis de sentimiento fue realizado mediante un diccionario construido manualmente. Este método identifica únicamente la presencia de determinadas palabras positivas y negativas y no considera completamente fenómenos como negaciones complejas, ironía, contexto narrativo o significado dependiente de la oración.