

Tarea 3 Procesamiento de Datos - Diseño de experimentos

Irwinng Rodriguez

August 2026

1 Introduction

En este trabajo se utilizaron reseñas de productos de Amazon, junto con la calificación numérica proporcionada por los usuarios. Las reseñas fueron clasificadas en tres categorías de sentimiento: negativo, neutral y positivo. Posteriormente, el texto fue transformado mediante TF-IDF y se compararon tres algoritmos de clasificación: Regresión Logística, Naive Bayes Multinomial y Máquinas de Vectores de Soporte con kernel lineal (SVM Lineal).

2 Objetivo

Diseñar y ejecutar los experimentos para comparar diferentes modelos de clasificación de texto y sus respectivos hiperparámetros, utilizando reseñas de Amazon representadas mediante TF-IDF, con el propósito de identificar la configuración que obtenga el mejor desempeño en la clasificación de sentimientos negativo, neutral y positivo.

3 Metodología

El conjunto de datos utilizado contiene reseñas realizadas por usuarios de Amazon. El archivo original presentó un total de 4,915 registros y 12 variables.

Para el problema de clasificación se seleccionaron principalmente las variables:

- **reviewText**: contenido textual de la reseña.
- **overall**: calificación numérica otorgada por el usuario.

Después de eliminar registros con valores faltantes, el conjunto final estuvo formado por 4,914 reseñas.

El conjunto de datos se dividió utilizando una proporción de 80% para entrenamiento y 20% para prueba.

La partición resultante fue:

- Entrenamiento: 3,931 reseñas.
- Prueba: 983 reseñas.

Se utilizó una partición estratificada para mantener aproximadamente la misma distribución de clases en ambos conjuntos.

Las reseñas fueron transformadas a vectores numéricos utilizando el método TF-IDF.

Para comparar los algoritmos de manera consistente se implementaron *pipelines* que integraron la vectorización TF-IDF y el modelo de clasificación.

Los algoritmos evaluados fueron:

1. Regresión Logística.
2. Naive Bayes Multinomial.
3. SVM Lineal.

4 Resultados

La Regresión Logística obtuvo el mayor F1-macro durante la validación cruzada, con un valor de 0.5814. El segundo mejor resultado correspondió al SVM Lineal, con 0.5738, mientras que Naive Bayes presentó un valor de 0.4932.

La diferencia entre Regresión Logística y SVM fue relativamente pequeña, mientras que Naive Bayes presentó un desempeño inferior en la separación equilibrada de las tres clases.

De las 4,914 observaciones analizadas, 4,448 pertenecen a la categoría positiva, mientras que solamente 324 son negativas y 142 neutrales. Esto condiciona considerablemente el desempeño de los modelos.

5 Conclusiones

El diseño experimental desarrollado permitió comparar sistemáticamente tres algoritmos de clasificación de texto: Regresión Logística, Naive Bayes Multinomial y SVM Lineal, evaluando diferentes configuraciones de hiperparámetros y representaciones TF-IDF.

Durante la validación cruzada, la Regresión Logística obtuvo el mejor F1-macro con 0.5814, seguida del SVM Lineal con 0.5738, sin embargo, al evaluar los mejores modelos sobre el conjunto independiente de prueba, el SVM Lineal alcanzó el mayor F1-macro con 0.5524.